ML Challenge S12 — Predicción de entregas tardías

Descripción del proyecto

Este proyecto corresponde al laboratorio S12 del reto de Machine Learning de Data Analytics. El objetivo es analizar pedidos del conjunto de datos público **Brazilian E-Commerce Public Dataset by Olist** y construir modelos base para estudiar la entrega tardía de pedidos.

El trabajo se desarrolla en un notebook de Python y contempla clasificación, evaluación de errores y una regresión para estimar la duración de las entregas.

Objetivos

• Preparar e integrar información de pedidos, productos, clientes, vendedores y pagos.

• Construir una variable objetivo que identifique si un pedido fue entregado después de la fecha estimada.

• Entrenar y comparar modelos de regresión logística con y sin balanceo de clases.

• Evaluar los modelos mediante Accuracy, Precision, Recall, F1, ROC-AUC y Average Precision.

• Analizar errores por mes de compra y estado del cliente.

• Estimar el costo empresarial de falsos positivos y falsos negativos.

• Entrenar una regresión Ridge para estimar la duración de las entregas y medir su error absoluto medio (MAE).

Estructura del repositorio

```
data/
  raw/          # Datos originales locales; no subir los CSV a GitHub
  processed/    # Datos procesados locales, si se necesitan
notebooks/
  S12_ML_Challenge.ipynb
src/            # Código reutilizable para futuros retos
reports/
  S12_resultados_ID_23.json
README.md
```

Datos

Se utiliza el conjunto público de Olist. El notebook descarga los archivos necesarios desde una fuente pública y los integra durante la ejecución.

• `data/raw/`: puede utilizarse para almacenar datos originales localmente, pero no se deben publicar los CSV originales.

• `data/processed/`: reservado para datos preparados que se decida conservar localmente. Para este laboratorio no es necesario guardar la muestra de 35.000 pedidos.

• No subir al repositorio la muestra completa ni otros archivos de datos derivados que contengan los pedidos.

Metodología

1. Cargar e integrar las tablas del conjunto de datos.

2. Convertir y validar fechas, y conservar pedidos entregados con fechas válidas.

3. Construir variables predictoras y la variable objetivo `is_late`.

4. Crear una muestra reproducible de 35.000 pedidos usando el ID individual **23** y la semilla correspondiente (`1023`).

5. Dividir los datos en entrenamiento (70 %), validación (15 %) y prueba (15 %).

6. Entrenar regresión logística sin balanceo (`class_weight=None`) y con balanceo (`class_weight='balanced'`).

7. Evaluar métricas, matrices de confusión, errores por segmentos y costo empresarial.

8. Usar Ridge para estimar los días de entrega y calcular el MAE.

La variable dias_entrega se utiliza como objetivo de regresión y no como predictor de la clasificación. El conjunto de prueba debe reservarse para la evaluación final indicada en el curso.

Evaluación y costos

Las métricas de clasificación incluyen Accuracy, Precision, Recall, F1, ROC-AUC y Average Precision. También se comparan los errores por mes de compra y estado del cliente.

Para el ejercicio de costo empresarial se utilizan los supuestos definidos en la guía:

• Falso positivo: **R$ 8**.

• Falso negativo: **R$ 35**.

Estos valores son supuestos didácticos para el ejercicio y no costos verificados de Olist.

La regresión Ridge se evalúa con MAE, expresado en días. El valor obtenido debe corresponder a la ejecución del notebook.

Requisitos

• Python 3

• Jupyter Notebook o Google Colab

• Acceso a Internet para descargar los datos de Olist

• Bibliotecas: `numpy`, `pandas`, `scikit-learn` y `matplotlib`

Cómo ejecutar

1. Abrir `notebooks/S12_ML_Challenge.ipynb` en Google Colab o Jupyter.

2. Confirmar que `ID_ESTUDIANTE = 23`.

3. Ejecutar el notebook completo desde el inicio y en orden.

4. Revisar que las celdas finalicen sin errores y que las comprobaciones (`assert`) se cumplan.

5. Guardar el notebook ejecutado.

6. Generar y guardar el reporte `reports/S12_resultados_ID_23.json` desde las celdas de reporte del notebook.

Entregables

• `notebooks/S12_ML_Challenge.ipynb`: notebook con preparación, entrenamiento, evaluación, gráficas e interpretación.

• `reports/S12_resultados_ID_23.json`: resultados generados por el notebook.

No se deben subir los CSV originales ni la muestra completa de 35.000 pedidos.

Reproducibilidad

Se mantiene el ID individual 23, la semilla asociada y las particiones de datos para que los resultados puedan reproducirse. Para comparar modelos, se debe utilizar el mismo conjunto de validación.

Autor

Estudiante: ID 23